

Integrantes Grupo: César Meneses, Fabián Ortega

Responda las siguientes preguntas en el espacio asignado.

Pregunta 1 (3 puntos):

(1 pto.) Elabore un flujograma del sistema “antiguo” con el que atendía la clínica. ¿Dónde se generan las esperas en el sistema? ¿Cuál es el cuello de botella?

En el sistema previo al triage, todo paciente seguía un recorrido estrictamente secuencial. Tras firmar la hoja numerada en recepción (2 minutos), el recepcionista solicitaba la ficha clínica al Departamento de Registros Médicos, la cual demoraba entre 8 y 9 minutos en ser trasladada físicamente hasta la clínica. Un oficinista revisaba luego la ficha durante unos 5 minutos para verificar que los reportes de laboratorio y los datos del paciente estuvieran actualizados, y la colocaba en una pila ordenada por orden de llegada. Cuando la ficha llegaba al tope de la pila, el paciente era visto por la primera enfermera disponible, quien realizaba un diagnóstico de aproximadamente 10 minutos. Si el problema era menor, lo resolvía en el acto (40% de los casos); si no, el paciente debía volver a la sala de espera para ser atendido por un médico (60% restante).




Figura 1. Flujograma del sistema antiguo (pre-triage).

Las esperas se generaban en tres puntos críticos. La primera y más severa ocurría entre el sign-in y el primer contacto con la enfermera, que promediaba 23 minutos, llegando a superar los 35 minutos para el 22% de los pacientes. La segunda era administrativa: la búsqueda y el traslado físico de la ficha consumían cerca de 13 minutos antes incluso de que el paciente pudiera ser evaluado. La tercera era la espera intermedia de derivación: el 60% de los pacientes

que requería un médico debía volver a la cola, con un retraso adicional promedio de 10 minutos. A esto se sumaba que quienes solicitaban un médico específico (19% de la demanda) esperaban en promedio 40 minutos, ya que no recibían prioridad sobre quienes habían llegado antes.

El cuello de botella del sistema era la etapa de enfermería. Como el 100% de los pacientes debía pasar obligatoriamente por una consulta de 10 minutos, pero las enfermeras solo resolvían de forma definitiva el 40% de los casos, su capacidad se saturaba atendiendo evaluaciones que, en el 60% de las ocasiones, debían repetirse después en la consulta médica. Tal como señaló el Dr. Postel, cada enfermera decidía de manera independiente el alcance de la atención, lo que producía inconsistencia, alta variabilidad y, sobre todo, una duplicación de esfuerzos que congestionaba todo el flujo aguas abajo.

(1 pto.) ¿Qué problema presentaba el sistema antiguo? ¿En qué métricas se reflejaba este problema? ¿Cuál es la variabilidad que tiene el sistema? Señale al menos 3 de cada una y comente por qué es un problema.

El sistema antiguo presentaba al menos tres problemas de fondo. En primer lugar, tiempos de espera excesivos e impredecibles que no se correlacionaban con la urgencia ni la simplicidad de la dolencia: un paciente podía esperar casi una hora por la renovación de una receta. En segundo lugar, una duplicación ineficiente de los esfuerzos médicos, pues el 60% de los pacientes pasaba por dos evaluaciones completas e independientes (enfermera y luego médico), repitiendo preguntas y exámenes básicos. En tercer lugar, una mala percepción del servicio: la sala de espera saturada y el trato impersonal llevaban a que los pacientes describieran la clínica como “fría, ineficiente e impersonal”, e incluso a que algunos evitaran atenderse, afectando la prevención en salud.

Estos problemas se reflejaban en métricas concretas: el tiempo de espera promedio al primer contacto era de 23 minutos; el 22% de los pacientes superaba los 35 minutos de espera para ver a la enfermera; la tasa de derivación a médico alcanzaba el 60%; y el tiempo de espera de derivación promediaba 10 minutos adicionales. Cada una de estas cifras evidencia un sistema cuya capacidad no lograba absorber la demanda en los períodos punta y que, además, gastaba capacidad en trabajo redundante.

Respecto de la variabilidad, el sistema enfrentaba al menos tres fuentes. La primera es la variabilidad en la tasa de llegada: la demanda se concentraba en las horas intermedias del día (18,2 llegadas/hora entre 8 y 9 AM, frente a apenas 2,8 entre 5 y 6 PM), lo que generaba sobrecarga matinal y ociosidad al cierre. La segunda es la variabilidad en los tiempos de servicio según la severidad: una dolencia podía resolverse en 5 minutos (un resfrío o un lavado de oído) o requerir 30 a 40 minutos (una apendicitis o un dolor de pecho). La tercera es la variabilidad por solicitudes específicas: el 19% de los pacientes exigía un proveedor en particular, lo que impedía operar con una fila única y sobrecargaba a ciertos médicos mientras otros quedaban subutilizados. Toda variabilidad, combinada con alta utilización, hace que el tiempo en cola se dispare (ecuación de Kingman), por lo que constituye el motor de las largas esperas observadas.

(1 pto.) Elabore un flujograma del sistema “nuevo” con el que atendía la clínica. ¿Cuál es la mayor diferencia? ¿Cómo se hace cargo de las esperas y la variabilidad? ¿En qué métrica se debería reflejar los cambios del nuevo sistema? ¿Por qué debería ser mejor?

El sistema nuevo, implementado por Kathryn Angell en septiembre de 1979, introdujo un triage a la entrada. El paciente completa un formulario de visita ambulatoria (AVF) y, mientras un oficinista solicita su ficha en paralelo, es llamado por una de las dos coordinadoras de triage —enfermeras registradas altamente experimentadas— que en 3 a 4 minutos determinan la naturaleza del problema y derivan al paciente al recurso adecuado: una enfermera practicante (NP) si la dolencia cae en una de las 13 categorías protocolizadas, o un médico (MD) en caso contrario o ante mayor gravedad. Los casos de emergencia se priorizan de inmediato.




Figura 2. Flujograma del sistema nuevo (con triage).

La mayor diferencia es la paralelización y segmentación de los flujos. Se elimina el esquema en serie (enfermera → médico) que obligaba a todos a pasar por un mismo cuello de botella, y se reemplaza por un enrutamiento que divide la demanda en dos colas paralelas según complejidad. El triage actúa como un clasificador que absorbe la variabilidad de severidad en la entrada y la canaliza al recurso correcto; además, en períodos de alta demanda las coordinadoras redirigen dinámicamente casos dudosos hacia los médicos para descongestionar a las NPs. La búsqueda física de la ficha, antes secuencial, ahora se ejecuta en paralelo mientras el paciente espera el triage, eliminando ese tiempo muerto de la ruta crítica.

Los cambios deberían reflejarse en un menor tiempo total de permanencia en la clínica, en una alta tasa de resolución directa de las NPs (cercana al 95%, sin derivaciones adicionales) y en tiempos de espera más balanceados entre médicos y enfermeras practicantes. El nuevo sistema debería ser mejor porque elimina la redundancia de atención del 60% de los pacientes: al segmentar por complejidad, reserva la costosa capacidad médica para los diagnósticos avanzados y otorga autonomía a las NPs bajo guías clínicas, acortando los tiempos unitarios de procesamiento del conjunto del sistema. No obstante, conviene notar que en la práctica el beneficio fue parcial: las NPs absorbieron solo el 33% de la carga (y no más), en parte porque las coordinadoras, al ver saturadas a las practicantes, terminaban derivando más pacientes a los médicos.

Pregunta 2 (3 puntos):

(0.5 pto) Determine la utilización del sistema desde su apertura a las 8 AM hasta las 5 PM, para el día promedio y para el lunes.

Análisis de Caso 4 University Health Services

La utilización se obtiene comparando la carga de trabajo demandada (en horas de consulta) con la capacidad programada (en horas-profesional) en la ventana de 8 AM a 5 PM. Según el Exhibit 2, en ese tramo ingresan en promedio 140,2 pacientes al día (143 considerando el día completo), y el lunes, día punta, esa cifra escala a aproximadamente 159,8 pacientes. Bajo el sistema de triage el 67% de los pacientes termina siendo atendido por un médico y el 33% por una enfermera practicante; los médicos atienden 3,1 pacientes por hora y las NPs 1,8. La capacidad programada en el tramo se obtiene sumando las horas-profesional del Exhibit 4.

Recurso	Demanda (h)	Capacidad prog. (h)	Utilización ρ
Médicos — día promedio	30,3	28,1	108% (inestable)
NPs — día promedio	25,7	29,5	87%
Médicos — lunes	34,5	28,5	121% (muy inestable)
NPs — lunes	29,3	29,5	99% (al límite)

El resultado es contundente: la capacidad médica está sobrepasada incluso en un día promedio (108%) y colapsa el lunes (121%), mientras que las NPs operan con holgura el día promedio (87%) pero quedan al borde de la saturación el lunes (99%). Es importante matizar que una utilización superior al 100% no significa una cola literalmente infinita: en la realidad el desbalance se absorbe porque el personal permanece después de las 6 PM despachando la cola acumulada y porque parte de la capacidad proviene de fracciones de hora y tiempos de reserva. Más relevante aún, el análisis hora a hora muestra que la capacidad está mal calzada en el tiempo: a las 8-9 AM la utilización médica supera el 190%, mientras que cerca del mediodía cae por debajo del 80%. Buena parte del problema es de timing, no solo de dotación.

(0.5 pto) ¿Cuál sería la cantidad necesaria de doctores para un nivel de utilización de 100%, 90%, 75% y 60%? (0.5 pto) ¿Cuál sería el tiempo de espera de los pacientes en cada nivel?

La cantidad de médicos requerida se obtiene de la carga ofrecida, $a = \lambda/\mu$. Para el día promedio, la tasa de llegada a la cola médica es $\lambda = 93,9$ pacientes / 9 horas = 10,44 pac/hora, de modo que $a = 10,44 / 3,1 = 3,37$ médicos equivalentes para operar a 100% de utilización. Para alcanzar un nivel objetivo ρ se necesita $c = a/\rho$ médicos. El tiempo de espera en cola se estima con el modelo M/M/c (fórmula de Erlang C) evaluado en el número entero de médicos. Para el lunes, $\lambda = 11,90$ pac/hora y $a = 3,84$.

Caso	ρ objetivo	Médicos (cont.)	Médicos (entero)	ρ real	Espera W_q
Día promedio	100%	3,37	3	112%	∞ (inestable)
	90%	3,74	4	84,2%	20,6 min
	75%	4,49	5	67,3%	4,0 min
	60%	5,61	6	56,1%	1,1 min
Lunes (punta)	100%	3,84	3	128%	∞ (inestable)
	90%	4,26	4	95,9%	108,7 min
	75%	5,12	5	76,8%	8,2 min
	60%	6,40	6	64,0%	2,2 min

La tabla revela la enorme sensibilidad del sistema cerca de la saturación: el día promedio, pasar de 4 a 5 médicos reduce la espera de 20,6 a 4,0 minutos, y el lunes operar con 4 médicos (95,9% de utilización) dispara la espera a casi

dos horas, mientras que con 5 cae a 8,2 minutos. Este comportamiento ilustra por qué nunca conviene planificar un servicio al 100% de utilización: en la vecindad de $\rho = 1$ el tiempo en cola crece de forma explosiva.

(0.5 pto) ¿Qué haría usted? Comente la cantidad de doctores que asignaría a la clínica y por qué tomaría esa decisión.

Asignaría de forma permanente 5 médicos en promedio de martes a viernes (utilización cercana al 67%, con esperas en torno a 4 minutos) y reforzaría a 6 médicos los lunes (utilización del 64%, esperas de 2 minutos). La razón es triple. Primero, evitar el colapso del lunes, donde mantener 4 médicos produce esperas de casi dos horas que son inaceptables para la meta de servicio de UHS. Segundo, disponer de un colchón de capacidad para absorber la demanda oculta: el caso reporta que las “walk-in appointments” —pacientes que sus propios médicos citan informalmente en la clínica— llegan a ocupar al 100% a dos de cada cinco médicos, reduciendo en un 40% la capacidad real disponible para los pacientes espontáneos. Operar con holgura teórica protege al sistema de esa fuga. Tercero, el costo relativo de un médico adicional (salarios de 35.000 a 55.000 USD anuales más 18,5% de beneficios) es bajo frente a la mejora en satisfacción y a las horas extra que el personal de enfermería y recepción debe trabajar para despachar las colas pasadas las 6 PM.

Con todo, antes de sumar dotación recomendaría reasignar las horas-médico ya existentes hacia el peak de 8 a 10 AM, donde la utilización supera el 190%, trasladándolas desde el tramo del mediodía donde la clínica está subutilizada. Calzar la oferta con la curva real de llegadas es la palanca más barata y de mayor impacto, y complementa —no reemplaza— la decisión de dotación anterior.

(1 pto.) Elabore un modelo de simulación del proceso. Muestre cómo genera las esperas, las colas y las atenciones. Presente los resultados del modelo y proponga al menos dos soluciones y cuáles son los impactos en los resultados.

Se construyó un modelo de simulación de eventos discretos (en Python, archivo simulacion.py) que reproduce un día de operación de la clínica. El modelo genera las llegadas mediante procesos de Poisson con las tasas horarias del Exhibit 2, hace pasar a cada paciente por la cola de triage (2 coordinadoras, 3 a 4 minutos) y luego por la cola de médicos o de NPs, con la dotación variable hora a hora del Exhibit 4 y tiempos de servicio exponenciales. Este enfoque es necesario precisamente porque, con utilización superior al 100%, el modelo analítico M/M/c entrega esperas infinitas; la simulación, en cambio, reinicia cada día y contabiliza los pacientes que quedan en cola después de las 6 PM (“rezagados”), capturando lo que realmente ocurre bajo sobrecarga transitoria. Se promediaron 3.000 días por escenario.

Escenario	Espera triage	Espera MD	Espera NP	Rezagados/día
Día prom. — Base	0,53 min	62,0 min	24,2 min	11,9 pac
Día prom. — Sol. 1 (pooling)	0,53 min	59,8 min	20,9 min	11,4 pac
Día prom. — Sol. 2 (NP 50%)	0,53 min	19,0 min	100,8 min	16,0 pac
Lunes — Base	0,74 min	105,0 min	36,5 min	21,8 pac
Lunes — Sol. 1 (pooling)	0,74 min	105,7 min	33,0 min	21,6 pac
Lunes — Sol. 2 (NP 50%)	0,74 min	28,7 min	152,8 min	25,5 pac

La simulación confirma el diagnóstico: en el escenario base la espera para ver a un médico ronda los 62 minutos en un día promedio (y supera los 100 el lunes), muy por encima de los 24 minutos de las NPs. Esto refleja tanto el desbalance de carga como la sobrecarga estructural del recurso médico ($\rho \approx 108\%$), y explica los casi 12 pacientes

diarios que siguen en el sistema al cierre. A partir de aquí se evaluaron dos soluciones. La primera, eliminar la posibilidad de solicitar un médico específico (pooling perfecto de la capacidad médica), reduce la espera de los médicos de 62 a 60 minutos sin costo alguno de contratación; el efecto del pooling es real pero modesto, coherente con que el problema de fondo es la sobrecarga agregada y no solo la ausencia de una fila única. La segunda, expandir las guías clínicas de las NPs para que absorban el 50% de los pacientes en lugar del 33%, reduce drásticamente la espera médica (a 19 minutos), pero —si no se aumenta la dotación de NPs— traslada el cuello de botella hacia ellas y hace explotar su cola a más de 100 minutos, con cerca de 16 rezagados diarios. La conclusión es que esta segunda medida solo es viable si se acompaña de un incremento equivalente de la capacidad de las NPs (contratando o liberando sus horas administrativas); de lo contrario, simplemente se traslada el problema en vez de resolverlo. La recomendación final combina ambas palancas con el recalce horario de la dotación médica hacia el peak matinal.