

## La “Física en la Fabrica”

**Entender y manejar la variabilidad e incertidumbre.**



## Impacto de Variabilidad

- Esta en todas partes. La Meta.
- Trabajamos con el promedio. Mente.
- Fuentes de variabilidad.
- Efectos:
  - Ingresos.
  - Costos.



## Variabilidad e Incertidumbre

- Son diferentes?
- La demanda.
- La capacidad de mi sistema productivo.
- Es importante notar la diferencia.
- Tipos de variabilidad en la producción y servicios.



## Importante



¿Porqué sucede esto?  
¿otros ejemplos?



## Variabilidad

- ¿Porqué?

*Por que la capacidad no satisface la demanda.*


Ejemplo: Sala de Emergencia

- Atiende a una tasa de 10 personas/hora
- Antes de 7pm y después de 9pm, pacientes llegan a una tasa de 5 personas/hora
- Entre las 7pm y 9pm, paciente llegan a tasa de 20 personas por hora



## Variabilidad

- ¿Qué sucede?



- En este tipo de casos, podemos “predecir” que sucederá



## Variabilidad

- Pero, en otros casos, a pesar de mayor capacidad vemos colas de espera...
- En muchas situaciones, la tasa de llegada no supera la capacidad en el largo plazo y en periodos predecibles, pero si en el corto plazo y por periodos no predecibles.




## VARIABILIDAD

Alejandro Mac Cawley – 2026



306

## Costos en líneas de espera



Alejandro Mac Cawley – 2026



307

## Más ejemplos


| Situación               | Llegadas  | Servidor   | Servicio           |
|-------------------------|-----------|------------|--------------------|
| Banco                   | Clientes  | Cajero     | Depósito, etc.     |
| Hospital                | Pacientes | Doctor     | Tratamiento        |
| Intersección de tráfico | Autos     | Semáforo   | Tráfico controlado |
| Línea de ensamble       | Partes    | Trabajador | Ensamble           |

Alejandro Mac Cawley – 2026



308

## Manejando la física de las colas




Alejandro Mac Cawley – 2026



309

## Características de líneas de espera




- Población de clientes puede ser finita o infinita
- Patrón de llegada puede ser random
- Clientes pueden ser o no ser pacientes
- Largo de la cola puede ser limitado
- Clientes son servidos en una secuencia FIFO
- Pueden haber más de una cola
- Tiempos de servicio pueden ser random
- Puede haber más de un servidor

Alejandro Mac Cawley – 2026



310

## Medidas de desempeño



**Desempeño del sistema = F( Parámetros del sistema )**

$\gamma$  Output/Throughput rate  
 $L$  Nivel inventario / largo cola  
 $W$  Tiempo de espera  
 $C$  Tiempo de ciclo  
 $P_{full}$  Probabilidad de cola llena

$\lambda$  Tasa de llegada  
 $\mu$  Tasa de servicio  
 $M$  Tiempo de servicio  
 $S$  Número de servidores  
 $R$  Capacidad de la cola (buffer)  
 $\rho$  Utilización de capacidad  
 $K$  Clases de servicio  
 $\pi$  Política de servicio


Alejandro Mac Cawley – 2026




311

## Tipos de líneas de espera

### Canal Simple – Una fase



### Canal Simple – Multi-fase




Alejandro Mac Cawley – 2026



312

## Tipos de líneas de espera

### Multi-servidor – Una fase



Ejemplo: banco, correo, etc.


Alejandro Mac Cawley – 2026



313

## Tipos de líneas de espera

### Multi-servidor – Multi-fase



Ejemplo: Lavandería, sistema de producción make-to-order, etc




## Tipos de líneas de espera: ejemplos

|                 | Una fase                      | Multi-fase             |
|-----------------|-------------------------------|------------------------|
| Servidor simple | Peluquero con una silla       | Lavado de auto         |
| Multi-servidor  | Ventanillas de cajeros bancos | Admisión en hospitales |



## Analicemos una cola simple (1 servidor)



### Cantidades importantes:

- Tasa llegada:  $\lambda$  (ej: clientes/hr, paquetes/seg, etc)
- Tasa servicio:  $\mu$  (ej: clientes/hr, etc)
- # unidades en el sistema:  $L_S$
- # unidades en la cola:  $L_Q$
- Tiempo en el sistema:  $W_S$  (Throughput Time)
- Tiempo en la cola:  $W_Q$
- Utilización del servidor:  $\rho$



## Sistema Productivo

- Performance:
  - Tiempo de ciclo de producción o tiempo de flujo. (FT)
  - Work in Progress (WIP)
  - Tasa de producción (throughput).
- Se puede medir el FT y WIP en espera.
- Cual es el objetivo. Trade-off.



## Analicemos la Variabilidad

- Proceso:
  - En los tiempos.
  - En el flujo.
- Efecto de las tasas y las características de la aleatoriedad.
- ¿Cómo medimos la variabilidad? Varianza
- Coeficiente de variabilidad (c): Si T es una variable aleatoria.  $E(T) = t$ ,  $\text{Var}(T) = \sigma^2$ .

$$c_T = \frac{\sigma}{t} = \frac{\sqrt{\text{Var}(T)}}{E(T)}$$



## Variabilidad

- Definición:
 

“Cualquier cosa que cause a un sistema alejarse de un comportamiento regular y predecible”
- Causas de Variabilidad:
 

|                             |                            |
|-----------------------------|----------------------------|
| – Falla de máquinas         | ✓ Movimiento de material   |
| – Setups                    | ✓ Fluctuaciones de demanda |
| – Falta de materiales       | ✓ Cambio de ordenes        |
| – Pérdida de velocidad      | ✓ Variedad de productos    |
| – Reproceso                 |                            |
| – Indisponibilidad          |                            |
| – Diferencia de capacidades |                            |



## Entender la Variabilidad

- Entender la variabilidad es *crítico* para un manejo efectivo y eficiente de las operaciones
- Elaborar dos premisas básicas:
  1. Ser capaz de medir consistente y apropiadamente la variabilidad
  2. Desarrollar la causa-efecto de la variabilidad en los sistemas productivos



## Sistema Simple: Cola M/M/1

- $\lambda$ : Tasa llegada de “clientes”. ( $1/\lambda$ : tiempo medio)
- $\mu$ : Tasa de atención del servidor. ( $1/\mu$ : tiempo medio)
- Llegada y servicios son Poisson. Distribución exponencial.
- Sea:

$$\rho = \frac{\lambda}{\mu}$$

- Podemos obtener:

$$L = \frac{\rho}{1 - \rho}, \quad W = \frac{1}{\mu(1 - \rho)}$$

- Medidos en la espera:

$$L_q = \frac{\rho^2}{1 - \rho}, \quad W_q = \frac{\rho}{\mu(1 - \rho)}$$



## Funciona?

- Que pasa si tenemos un proceso de llegada exponencial, con un cliente cada 3 minutos. Si el tiempo de proceso es en promedio 2 minutos por unidad, exponencial.

$$\lambda = 1/3 \quad \mu = 1/2 \quad \rho = \left(1/3 / 1/2\right) = 2/3 = 0.666$$

$$L = 2 \quad W = 6$$

$$L_q = 4/3 \quad W_q = 4$$

- Simulando el proceso?



## Little



- Relación entre L y W.

$$L = \lambda \times W$$

- Formula de Little (J.D. Little MIT, demostró en 1961).
- Interesante: Es valida en cualquier proceso de llegada y servicio y cualquier disciplina en la cola.
- Requisito: sistema este en “estado estacionario”.



## Extrapolaciones de Little

- Trabajo en Proceso (WIP), Throughput (TH) y Tiempo de Ciclo (Espera+Trabajo):

$$WIP = TH \times TC$$

- Ej: TH: 0.4 unid/h TC: 2 Hrs.  $0.4 \times 2 = 0.8$  Trabajos en cola.
- Como reducimos el tiempo de ciclo?

$$TC = \frac{WIP}{TH}$$



## ¿Para qué la variabilidad?


SIX SIGMA

| Cantidad<br>Procesos | $\pm 3\sigma$ | $\pm 4\sigma$ | $\pm 5\sigma$ | $\pm 6\sigma$ |
|----------------------|---------------|---------------|---------------|---------------|
| 1                    | 93,32%        | 99,379%       | 99,9767%      | 99,9996%      |
| 7                    | 61,63%        | 95,7332%      | 99,84%        | 100,00%       |
| 10                   | 50,09%        | 93,9607%      | 99,77%        | 100,00%       |
| 20                   | 25,09%        | 88,2861%      | 99,54%        | 99,99%        |
| 40                   | 6,29%         | 77,9444%      | 99,07%        | 99,98%        |
| 80                   | 0,40%         | 60,7533%      | 98,15%        | 99,97%        |
| 100                  | 0,10%         | 53,6367%      | 97,70%        | 99,96%        |
| 150                  | 0,00%         | 39,2820%      | 96,56%        | 99,94%        |
| 200                  | 0,00%         | 28,7690%      | 95,95%        | 99,92%        |
| 300                  | 0,00%         | 15,4307%      | 95,25%        | 99,88%        |
| 400                  | 0,00%         | 8,2765%       | 91,10%        | 99,84%        |
| 500                  | 0,00%         | 4,4393%       | 89,00%        | 99,80%        |
| 600                  | 0,00%         | 2,3811%       | 86,95%        | 99,76%        |
| 700                  | 0,00%         | 1,2771%       | 84,95%        | 99,72%        |
| 800                  | 0,00%         | 0,6850%       | 82,99%        | 99,68%        |
| 1000                 | 0,00%         | 0,1971%       | 79,21%        | 99,60%        |
| 1200                 | 0,00%         | 0,0567%       | 75,61%        | 99,52%        |
| 3000                 | 0,00%         | 0,0000%       | 49,70%        | 98,81%        |
| 17000                | 0,00%         | 0,0000%       | 1,90%         | 93,43%        |
| 38000                | 0,00%         | 0,0000%       | 0,01%         | 85,90%        |



## Variabilidad en lo tiempos de proceso

- Caracterizamos:
  - Tiempo medio de proceso efectivo,  $t_e$
  - Desviación standard del proceso efectivo,  $\sigma_e$
  - Coeficiente de variación.  $c_e = \frac{\sigma_e}{t_e}$



## Variabilidad debido a Fallas

- Notación:
  - $t_0$  = tiempo base de proceso
  - $\sigma_0$  = disv. estándar de tiempo base de proceso
  - $c_0$  = coeficiente variabilidad del tiempo base de proceso
  - $r_0 = \frac{1}{t_0}$  = capacidad base del proceso
  - $m_f$  = tiempo medio entre fallas
  - $m_r$  = tiempo medio de reparación
  - $c_r$  = coeficiente variabilidad del tiempo medio de reparación



## Variabilidad debido a Fallas

- Disponibilidad:  $A = \frac{m_f}{m_f + m_r}$
- Tiempo y tasa de proceso efectivo

$$r_e = Ar_0$$

$$t_e = t_0 / A$$



## Ejemplo variabilidad por fallas

- 2 maquinas:
    - M1:  $t_0 = 15$  min.  $\sigma_0 = 3,35$  min.
    - M2:  $t_0 = 15$  min.  $\sigma_0 = 3,35$  min. $\left. \begin{array}{l} \text{M1: } t_0 = 15 \text{ min. } \sigma_0 = 3,35 \text{ min.} \\ \text{M2: } t_0 = 15 \text{ min. } \sigma_0 = 3,35 \text{ min.} \end{array} \right\} c_0 = 0,223$   - M1: Tiempo medio entre falla:  $m_f = 744$  min. Tiempo medio de reparación:  $m_r = 248$  min.
  - M2: Tiempo entre falla promedio:  $m_f = 114$  min. Tiempo medio de reparación:  $m_r = 38$  min.
  - Reparación es variable con un  $c_r = 1.0$  para ambas máquinas.
- Que maquina prefiero?



## Ejemplo variabilidad por fallas

- Disponibilidad de cada máquina:
  - M1:  $A = \frac{m_f}{m_f + m_r} = \frac{744}{744 + 248} = 0,75$  ;  $t_e = t_0 / A = 15 / 0,75 = 20 \text{ min}$
  - M2:  $A = \frac{m_f}{m_f + m_r} = \frac{114}{114 + 38} = 0,75$  ;  $t_e = t_0 / A = 15 / 0,75 = 20 \text{ min}$
- Disponibilidad igual para ambas máquinas
- Necesito medir la coeficiente de variabilidad efectivo:

$$c_e^2 = c_0^2 + \text{factor por CA}$$

$$c_e^2 = c_0^2 + (1 + c_r^2)A(1 - A) \frac{m_r}{t_0}$$



## Ejemplo variabilidad por fallas

- Disponibilidad de cada máquina:
  - M1:  $c_e^2 = 0,223^2 + (1 + 1^2)0,75(1 - 0,75) \frac{248}{15} = 6,25$ 
    - Alta variabilidad
  - M2:  $c_e^2 = 0,223^2 + (1 + 1^2)0,75(1 - 0,75) \frac{38}{15} = 1$ 
    - Moderada variabilidad
- Conclusiones:
  - Fallas aumentan media, varianza y CV del tiempo efectivo de proceso
  - Para una disponibilidad constante, paradas largas e infrecuentes aumentan mas  $c_e^2$  que paradas cortas y frecuentes



## Setup

- Son predecibles, pero su duración puede ser aleatoria.

- Tiempo efectivo (tiempo prod.+ setup) :

$$t_e = t_o + \frac{t_s}{N_s}$$

- Varianza:

$$\sigma_e^2 = \sigma_o^2 + \frac{\sigma_s^2}{N_s} + \frac{N_s - 1}{N_s^2} t_s^2$$

- Coeficiente de variación:

$$c_e^2 = \frac{\sigma_e^2}{t_e^2}$$



## Ejemplo

- 2 maquinas:
  - M1:  $t_o=1.2$  hrs.  $c_o=0.5$ .
  - M2:  $t_o=1.0$  hrs.  $c_o=0.25$ .
  - M1: Flexible. Sin tiempos de setup.
  - M2: 10 unidades entre setup. Tiempo setup: 2 hrs.  $c_s=0.25$
- Que maquina prefiero?



## Ejemplo

- Capacidad efectiva:

$$r_{M1} = \frac{1}{t_o} = \frac{1}{1.2} = 0.833 \quad r_{M2} = \frac{1}{t_e} = \frac{1}{1 + 2/10} = 0.833$$

- Coeficiente variación:

$$c^2_{eM1} = 0.25 \quad c^2_{eM2} = 0.31$$

- Si el tiempo de setup cae a 1 hr cada  $N_s = 5$  unidades.

$$c^2_{\text{avg}} = 0.16$$



## Variabilidad en el Proceso/Flujo

- Al analizar la variabilidad en el proceso vemos al sistema como una cola.



## En sistemas productivos

- Calcular la distribución de salida puede ser muy difícil, pero es posible estimar variabilidad.



- Nos interesa estimar  $C_s$ . Se puede demostrar que:

$$(c_s)^2 \approx \rho^2 (c_e)^2 + (1 - \rho^2) (c_a)^2$$

- La variabilidad se propaga. Se afecta por:
  - Variabilidad llegada.
  - Variabilidad servicio.
  - Saturación del sistema.



## Variabilidad en el Proceso/Flujo

- Al analizar la variabilidad en el proceso vemos al sistema como una cola.
- Ya vimos una cola M/M/1.
- Que pasa si ahora hay distribuciones generales.



## Sistema G/G/1

- Tiempo Ciclo:

$$CT_q = \underbrace{\left( \frac{C_a^2 + C_e^2}{2} \right)}_{\bar{V}} \underbrace{\left( \frac{\rho}{1 - \rho} \right)}_{\bar{U}} \underbrace{t_e}_{\bar{T}}$$

- Medhi 1991 la derivo. Interesantes propiedades:
  - Exacta para M/M/1  $C_a=C_e$ .
  - Depende de la Variabilidad, Utilización y Tiempo.
- Ecuación de Kingman:  $CT=VUT$ .



## Ejemplo G/G/1

- Dos maquinas en serie:
  - M1:  $CVe1=6.25$  y  $CVa1=1.0$ . Tasa llegada  $G=2.875$  trabajos/hr. Procesa 3 trabajos por hr.
  - M2:  $CVa2=1.0$ . Idem las tasas.



## Ejemplo G/G/1

- Dos maquinas en serie:
  - M1:  $CVe1=6.25$  y  $CVa1=1.0$ .  $Te=20$  min. Tasa llegada  $G=2.875$  trabajos/hr. Procesa 3 trabajos por hr.
  - M2:  $CVa2=1.0$ .  $Te=20$  min. Idem las tasas.

$$CT_{q1} = \underbrace{\left( \frac{1 + 6.25}{2} \right)}_{\bar{V}} \underbrace{\left( \frac{0.9583}{1 - 0.9583} \right)}_{\bar{U}} \underbrace{20}_{\bar{T}} = 1667.5 \text{ min}$$

$$C_{s2}^2 \approx C_e^2 \rho^2 + C_a^2 (1 - \rho^2) = 6.25 \cdot 0.9583^2 + 1.0 \cdot (1 - 0.9583^2) = 5.82$$

$$CT_{q2} = \underbrace{\left( \frac{1 + 5.82}{2} \right)}_{\bar{V}} \underbrace{\left( \frac{0.9583}{1 - 0.9583} \right)}_{\bar{U}} \underbrace{20}_{\bar{T}} = 1568.97 \text{ min}$$



## Simulador

- Vamos a ir a un simulador.
- Bajar el archivo de la web. Dice Game.
- Son 5 estaciones de trabajo.
  - Su capacidad de producción va a estar dada por el lanzamiento de un dado. Hay distintos tipos de dados.
  - Las colas pueden tener capacidad.
  - Inventario Inicial



## Simulador

**THE DICE GAME**

RESET ROLL

Variance level of the different stations (1 = very low variance, 2 = low variance, ..., 5 = high variance, 6 = very high variance)

| Station | Level |
|---------|-------|
| 1       | 2     |
| 2       | 2     |
| 3       | 2     |
| 4       | 2     |
| 5       | 2     |

Initial inventory level at the different stations

|   |     |   |    |   |    |   |    |   |    |
|---|-----|---|----|---|----|---|----|---|----|
| 1 | ... | 2 | 10 | 3 | 10 | 4 | 10 | 5 | 10 |
|---|-----|---|----|---|----|---|----|---|----|

Maximum inventory level at the different stations

|   |     |   |    |   |    |   |    |   |    |
|---|-----|---|----|---|----|---|----|---|----|
| 1 | ... | 2 | 10 | 3 | 10 | 4 | 10 | 5 | 10 |
|---|-----|---|----|---|----|---|----|---|----|

SUBMIT

$P_b$  0  $P_s$  0  $P_s$  0  $P_s$  0  $P_s$  0

Output Ratio 0 %  
Number of Rolls 0

KATHOLIEKE UNIVERSITEIT  
**LEUVEN**

Alejandro Mac Cawley – 2026



342

**THE DICE GAME**

RESET ROLL

MOVE MOVE MOVE MOVE MOVE MOVE


2 2 2 2 2 2

|         |          |          |          |          |
|---------|----------|----------|----------|----------|
| $U_p$ 0 | $I_c$ 10 | $I_c$ 10 | $I_c$ 10 | $I_c$ 10 |
| $\mu$ 0 | $U_p$ 0  | $U_p$ 0  | $U_p$ 0  | $U_p$ 0  |
| $P_b$ 0 | $P_s$ 0  | $P_s$ 0  | $P_s$ 0  | $P_s$ 0  |


Output Ratio 0 %  
Number of Rolls 0

KATHOLIEKE UNIVERSITEIT  
**LEUVEN**

343




344



345

## Control de la utilización (sobrecarga)

- Para cualquier nivel de variación, algún nivel de utilización hace que el tiempo en cola explote
- Con frecuencia, un pequeño cambio marca una diferencia drástica



Alejandro Mac Cawley – 2026



346

## Capacidad finita: M/M/1/b

- La capacidad de espera es limitada a b clientes. Hay bloqueo.
- Si llega y cola esta llena abandona.
- Resultado:

$$L = \frac{\rho}{1 - \rho} - \frac{(b + 1)\rho^{b+1}}{1 - \rho^{b+1}}$$

- Tasa efectiva de clientes:

$$\lambda' = \lambda \left( \frac{1 - \rho^b}{1 - \rho^{b+1}} \right)$$

Alejandro Mac Cawley – 2026



347

## Múltiples servidores: M/M/c

- Factor de congestión:

$$\rho = \frac{\lambda}{c\mu}$$

- Resultado:

$$L_q = \frac{\rho}{1 - \rho} \times \text{Prob}(N > c)$$

- N es el numero de clientes en el sistema
- Espera:

$$W_q = \frac{\rho}{\lambda(1 - \rho)} \times \text{Prob}(N > c)$$




## Usos y limitaciones

- Se utilizan mucho en el ámbito de servicios.
- Ejemplos:
  - Disney.
  - Call-center.
  - Supermercados.
- El modelo Markoviano o de Poisson puede no ser el mejor para modelar situaciones productivas. ¿Por que?
- Distribuciones generales.



## En general



Alejandro Mac Cawley – 2026



350

## Pooling de la variabilidad

- Pooling es → Agregar, juntar.
- Si agregamos. Ejemplo.
- Formas:
  - Batch.
  - Unir inventario.
  - Compartir la espera. Ej. Jumbo.
- Objetivo es disminuir la variabilidad.

Alejandro Mac Cawley – 2026



351

## En sistemas productivos

- El buffer de capacidad finita mejora el performance **para los clientes que ingresan al sistema.**
- La presencia de un buffer reduce el throughput del sistema y este efecto aumenta la variabilidad.
- En sistemas interconectados los buffers amortiguan la propagación de la variabilidad.
- Mejorar el throughput: Aumentar el tamaño del buffer o reducir variabilidad.



## Psicología de líneas de espera

- Tiempo ocioso se percibe más largo que tiempo ocupado
- La ansiedad hace que las esperas parezcan más largas
- Esperas inciertas parecen más largas que las conocidas
- Esperas inexplicadas parecen ser más largas que aquellas con explicación
- Esperas injustas se hacen más largas que esperas justas
- Mientras más valioso el servicio, más tiempo estará dispuesto a esperar el cliente
- Esperas individuales se perciben más largas que esperas grupales



## Sugerencias para administrar las colas

- Determine un tiempo aceptable para sus clientes.
- Trate de desviar la atención de sus clientes cuando esperan.
- Informe a sus clientes qué es lo que deben esperar.
- Mantenga fuera de la vista de sus clientes a los empleados que no los están atendiendo.
- Segmente a los clientes.
- Capacite a sus servidores para que sean cordiales.
- Anime a los clientes para acudir durante períodos de poca actividad.
- Tenga la perspectiva a largo plazo de deshacerse de las colas.



## Conclusiones

- Todos los sistemas tienen variabilidad. Administrarla.
- El coeficiente de variación es la mejor forma de medir la variabilidad.
- La variabilidad se propaga. látigo.
- El tiempo de espera es el mayor componente del tiempo de ciclo.
- Si queremos reducir el CT, limitar el buffer. Reducimos el TH. Eq. Little.
- Pooling ayuda a disminuir la variabilidad.

